

Taller Econometría Corte 2

Presentado a:

Juan Carlos Vasquez Sora

Presentado Por:

Juan David Ocampo Medina

Universidad del Quindío

Facultad de Ciencias Económicas Administrativas y Contables

Economía

Armenia



Dickey-Fuller(SC.ST/CC, ST/CC, CT)	3
Dickey-Fuller(SC.ST/CC, ST/CC, CT) CP	7
ADF PIB	9
ADF CP	9
PHILLIPS-PERRON PIB	10
PHILLIPS-PERRON CP	10
KPSS PIB	11
KPSS CP	11
Pruebas de CO-Integración.....	12
Engle y Granger	12
EGCM.....	16
Phillips-Ouliaris	18
Prueba de Johansen	18
VAR.....	20
VEC.....	25
Conclusiones.....	30

Relación entre las variables, utilizare primeramente los datos macros de Europa que fueron entregados por el profesor, y utilizare YER(PIB) que hace referencia al PIB y Usare PCR(CP) que hace referencia al consumo del privado, lo hare para ver qué relaciones tienen estos dos llevado a un modelo econométrico y con que podemos concluir frente a el análisis de estas variables.

Iniciaremos con pruebas de raíz unitaria

Dickey-Fuller(SC.ST/CC, ST/CC, CT)

```
PIBT<-ts(PIB,start = c(1970,1),frequency = 4 )  
plot(PIBT)
```



Las dos graficas presenta tendencias ascendentes viendo el pasar de los años y se puede notar tendencia.

Dickey-Fuller(SC.ST/CC, ST/CC, CT) PIB

DF.SC.ST

```
Time series regression with "ts" data:
Start = 1970(2), End = 2017(4)


Call:
dynlm(formula = d(LNPIBT, 1) ~ L(LNPIBT, 1) - 1)

Residuals:
    Min       1Q   Median       3Q      Max
-0.035491 -0.002771  0.000338  0.003916  0.014050

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
L(LNPIBT, 1)  3.693e-04  3.261e-05   11.32  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.006359 on 190 degrees of freedom
Multiple R-squared:  0.403,    Adjusted R-squared:  0.3998
F-statistic: 128.3 on 1 and 190 DF,  p-value: < 2.2e-16
```

Tau Criticó = - 1,94



Aceptamos H_0 Por tanto la serie tiene tendencia

DF.CC.ST

```
Time series regression with "ts" data:
Start = 1970(2), End = 2017(4)


Call:
dynlm(formula = d(LNPIBT, 1) ~ L(LNPIBT, 1))

Residuals:
    Min       1Q   Median       3Q      Max
-0.033268 -0.002711  0.001131  0.003845  0.011769

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.099047   0.021773   4.549 9.62e-06 ***
L(LNPIBT, 1) -0.006648   0.001543  -4.309 2.64e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.006053 on 189 degrees of freedom
Multiple R-squared:  0.08944,    Adjusted R-squared:  0.08462
F-statistic: 18.57 on 1 and 189 DF,  p-value: 2.638e-05
```

Tau Critic = - 1,94



Se rechaza H0 por tanto no tiene tendencia

DF.CC. CT

```
Time series regression with "ts" data:
Start = 1970(2), End = 2017(4)


Call:
dynlm(formula = d(LNPIBT, 1) ~ L(LNPIBT, 1) + trend(LNPIBT))

Residuals:
    Min       1Q   Median       3Q      Max
-0.033171 -0.002441  0.000757  0.003686  0.011653

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.2405719   0.1285516   1.871   0.0628 .
L(LNPIBT, 1) -0.0170520   0.0094407  -1.806   0.0725 .
trend(LNPIBT)  0.0002172   0.0001944   1.117   0.2654
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.00605 on 188 degrees of freedom
Multiple R-squared:  0.09545,    Adjusted R-squared:  0.08582
F-statistic: 9.919 on 2 and 188 DF,  p-value: 8.033e-05
```

Tau Critico = -3,41



Dickey-Fuller(SC.ST/CC, ST/CC, CT) CP DF.SC.ST-

```
Time series regression with "ts" data:
Start = 1970(2), End = 2017(4)


Call:
dynlm(formula = d(LNCPT, 1) ~ L(LNCPT, 1) - 1)

Residuals:
    Min       1Q   Median       3Q      Max
-0.0218151 -0.0035436 -0.0001441  0.0035406  0.0158928

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
L(LNCPT, 1)  3.695e-04  3.005e-05   12.3   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.005621 on 190 degrees of freedom
Multiple R-squared:  0.4431,    Adjusted R-squared:  0.4402
F-statistic: 151.2 on 1 and 190 DF,  p-value: < 2.2e-16
```

Tau Critico = - 1,94



DF.CC.ST

```
Time series regression with "ts" data:
Start = 1970(2), End = 2017(4)


Call:
dynlm(formula = d(LNCPT, 1) ~ L(LNCPT, 1))

Residuals:
    Min       1Q   Median       3Q      Max
-0.0214367 -0.0026629  0.0007205  0.0028878  0.0114958

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.124235   0.017973   6.912 7.11e-11 ***
L(LNCPT, 1) -0.008807   0.001328  -6.633 3.37e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.005035 on 189 degrees of freedom
Multiple R-squared:  0.1888,    Adjusted R-squared:  0.1845
F-statistic: 43.99 on 1 and 189 DF,  p-value: 3.369e-10
```

Tau Critico = -2,86



Se rechaza H0 por lo tanto no tiene tendencia

DF.CC. CT

```
Time series regression with "ts" data:
Start = 1970(2), End = 2017(4)


Call:
dynlm(formula = d(LNCPT, 1) ~ L(LNCPT, 1) + trend(LNCPT))

Residuals:
    Min       1Q   Median       3Q      Max
-0.0211991 -0.0025603  0.0005135  0.0030537  0.0116177

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.704e-01  8.558e-02   1.991  0.0479 *
L(LNCPT, 1) -1.235e-02  6.553e-03  -1.884  0.0611 .
trend(LNCPT)  7.195e-05  1.304e-04   0.552  0.5819
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.005045 on 188 degrees of freedom
Multiple R-squared:  0.1901,    Adjusted R-squared:  0.1815
F-statistic: 22.07 on 2 and 188 DF,  p-value: 2.461e-09
```


Tau Critico = -3,41




Se acepta H_0 por tanto la serie acepta que tiene tendencia

EN conclusión, de la prueba Dickey-Fuller. Se puede concluir que las variables PIB y CP son variables que tienen tendencia

ADF PIB


Augmented Dickey-Fuller Test

data: LNPIBT
Dickey-Fuller = -1.8024, Lag order = 5, p-value = 0.6588
alternative hypothesis: stationary



Por tanto, se acepta que la serie tiene tendencia

ADF CP




```
Augmented Dickey-Fuller Test  
data: LNCPT  
Dickey-Fuller = -1.5728, Lag order = 5, p-value = 0.7549  
alternative hypothesis: stationary
```

Por tanto, se acepta que la serie tiene tendencia

PHILLIPS-PERRON PIB

```
Phillips-Perron Unit Root Test  
data: LNPIBT  
Dickey-Fuller Z(alpha) = -5.123, Truncation lag parameter = 4, p-value = 0.8216  
alternative hypothesis: stationary
```




Según la prueba, Nos indica que se acepta H_0 por tanto la serie tiene tendencia

PHILLIPS-PERRON CP

```
Phillips-Perron Unit Root Test  
data: LNCPT  
Dickey-Fuller Z(alpha) = -3.003, Truncation lag parameter = 4, p-value = 0.9334  
alternative hypothesis: stationary
```

> |



Se acepta H_0 por tanto la serie tiene tendencia, es decir CP tiene tendencia

KPSS PIB


```
> KPSS.LEST(LNPIBT)
```

KPSS Test for Level Stationarity

data: LNPIBT

KPSS Level = 3.8913, Truncation lag parameter = 4, p-value = 0.01

... ..



Se acepta rechaza H0 por tanto la serie no tiene tendencia y por ende es estacionaria

KPSS CP


```
> KPSS.LEST(LNCPT)
```

KPSS Test for Level Stationarity

data: LNCPT

KPSS Level = 3.8419, Truncation lag parameter = 4, p-value = 0.01

... ..



Se acepta H0 por tanto la serie no tiene tendencia y por ende la serie es estacionaria

Con respecto a las pruebas de raíz unitaria y siguiendo las indicaciones del profesor, la mayoría de las pruebas nos indica que se tiene tendencia, por consiguiente, las dos series que analizamos anteriormente con varias pruebas son o tienen en ellas tendencia.

Es decir que por votación de las pruebas anteriormente realizadas las series De PIBT Y CPT tienen TENDENCIA.


Pruebas de CO-Integración

Engle y Granger

Relaciones de largo plazo

SC, ST

```
· RL.PIBT.CP.SC.ST <- dynlm(LNPIBT~ LNCPT -1)  
· IN.RL.PIBT.CP.SC.ST<- residuals(RL.PIBT.CP.SC.ST)  
· plot(IN.RL.PIBT.CP.SC.ST)  
· PRU.RL.PIBT.CP.SC.ST<- dynlm( d(IN.RL.PIBT.CP.SC.ST)~ L(IN.RL.PIBT.CP.SC.ST),-1)  
· summary(PRU.RL.PIBT.CP.SC.ST)
```



En la anterior captura se crea la relación de largo plazo, luego se puede sacar la innovación, en primera instancia parece una serie sin tendencia, luego se contrasta y se crea un contraste con la innovación para hacer la prueba de raíz unitaria con el fin de identificar si la serie tiene tendencia

```

Time series regression with "numeric" data:
Start = 1(1), End = 191(1)

Call:
dynlm(formula = d(IN.RL.PIBT.CP.SC.ST) ~ L(IN.RL.PIBT.CP.SC.ST),
      data = -1)


Residuals:
    Min       1Q   Median       3Q      Max
-0.0234703 -0.0019051  0.0004018  0.0026560  0.0102156

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -2.188e-05  3.369e-04  -0.065   0.9483
L(IN.RL.PIBT.CP.SC.ST) -4.539e-02  2.111e-02  -2.150   0.0328 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.004656 on 189 degrees of freedom
Multiple R-squared:  0.02387,    Adjusted R-squared:  0.0187
F-statistic: 4.622 on 1 and 189 DF,  p-value: 0.03284

```

Tau crit = -2.76



De lo anterior podemos concluir que se acepta H_0 y por ende se acepta que la serie tiene tendencia

Relación de largo plazo

CC, ST


Realizo el procedimiento

```

> RL.PIBT.CP.CC.ST <- dynlm(LNPIBT~ LNCPT )
> IN.RL.PIBT.CP.CC.ST<- residuals(RL.PIBT.CP.CC.ST)
> plot(IN.RL.PIBT.CP.CC.ST)
> PRU.RL.PIBT.CP.CC.ST<- dynlm( d(IN.RL.PIBT.CP.CC.ST)~ L(IN.RL.PIBT.CP.CC.ST),-1)
> summary(PRU.RL.PIBT.CP.CC.ST)

```

Creo la relación a largo plazo, rescato la innovación y grafico



Es un grafica muy parecida a la anterior lo que me indica que, esta prueba tampoco va tener tendencia.

Luego realizo la Prueba de Raíz unitaria

```
Time series regression with "numeric" data:
Start = 1(1), End = 191(1)


Call:
dynlm(formula = d(IN.RL.PI.BT.CP.CC.ST) ~ L(IN.RL.PI.BT.CP.CC.ST),
      data = -1)

Residuals:
    Min       1Q   Median       3Q      Max
-0.0234788 -0.0018739  0.0004007  0.0026941  0.0098706

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.985e-05  3.369e-04   0.059   0.9531
L(IN.RL.PI.BT.CP.CC.ST) -4.026e-02  2.140e-02  -1.881   0.0615 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.004656 on 189 degrees of freedom
Multiple R-squared:  0.01838,    Adjusted R-squared:  0.01319
F-statistic:  3.54 on 1 and 189 DF,  p-value: 0.06145
```

Tau crit = -2.76



Ca en zona de aceptación por tanto se acepta H_0 y por ende se acepta que la serie tiene tendencia

Relación de largo plazo


CC, CT

Ahora añadimos haremos la prueba con largo plazo con constante y además con tendencia

```
> RL.PIBT.CP.CC.CT <- dynlm(LNPIBT~ LNCPT + trend(LNPIBT))  
> IN.RL.PIBT.CP.CC.CT<- residuals(RL.PIBT.CP.CC.CT)  
> plot(IN.RL.PIBT.CP.CC.CT)  
> PRU.RL.PIBT.CP.CC.CT<- dynlm( d(IN.RL.PIBT.CP.CC.CT)~ L(IN.RL.PIBT.CP.CC.CT),-1)  
> summary(PRU.RL.PIBT.CP.CC.CT)
```

Luego rescato la innovación

Y grafico



La grafica nos indica que esta prueba tiene tendencia

Luego hacemos la prueba de raíz unitaria

Y resumo.

```

Time series regression with "numeric" data:
Start = 1(1), End = 191(1)

Call:
dynlm(formula = d(IN.RL.PIBT.CP.CC.CT) ~ L(IN.RL.PIBT.CP.CC.CT),
      data = -1)


Residuals:
    Min       1Q   Median       3Q      Max
-0.025532 -0.001735  0.000209  0.002429  0.010304

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   1.967e-05  3.177e-04   0.062   0.9507
L(IN.RL.PIBT.CP.CC.CT) -1.069e-01  3.298e-02  -3.243   0.0014 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.00439 on 189 degrees of freedom
Multiple R-squared:  0.0527,    Adjusted R-squared:  0.04769
F-statistic: 10.52 on 1 and 189 DF,  p-value: 0.0014

```

Tau crit = -2.76



Cae en la zona de aceptación y por tanto se acepta H_0 lo que nos dice que se acepta que la serie es estacionaria.

EGCM

Corremos los comandos para la prueba egcm:

```

> EGGM.PIBT.PC <- egcm(LNPIBT, LNCPT)
> summary(EGGM.PIBT.PC)

```



```

Y[i] = 0.9641 X[i] - 0.0705 + R[i], R[i] = 0.9908 R[i-1] + eps[i], eps ~ N(0, 0.0045^2)
      (0.0039)      (0.0554)              (0.0213)

R[192] = -0.0343 (t = -2.227)

WARNING: X and Y do not appear to be cointegrated.

Unit Root Tests of Residuals


                                Statistic    p-value
Augmented Dickey Fuller (ADF)      -1.843    0.56477
Phillips-Perron (PP)              -10.913    0.35065
Pantula, Gonzales-Farias and Fuller (PGFF)  0.975    0.67739
Elliott, Rothenberg and Stock DF-GLS (ERSD) -1.144    0.52003
Johansen's Trace Test (JOT)       -74.714    0.00010
Schmidt and Phillips Rho (SPR)     -8.112    0.64449

Variances
SD(diff(X))      = 0.006327
SD(diff(Y))      = 0.005576
SD(diff(residuals)) = 0.004523
SD(residuals)    = 0.015419
SD(innovations)  = 0.004505

Half life        = 74.884331
R[last]          = -0.034338 (t=-2.23)
>

```

Sacamos los resultados luego de revisar que están bien y hago una gráfica para analizar



Observando la gráfica podría concluir que el modelo tiene tendencias. Y por ende, no es estacionarios me baso en esto debido a la cantidad de ondas que se forman básicamente de un mismo nivel en las gráficas.


Phillips-Ouliaris

Procedo a unir las series: `> TUNION <- ts.union(LNPIBT,LNCPT)`

Y Aplico la prueba

```
Phillips-Ouliaris Cointegration Test

data: TUNION
Phillips-Ouliaris demeaned = -9.1791, Truncation lag parameter = 1, p-value = 0.15
```



Se acepta H_0 por ende según esta prueba nos indica que la serie no está Co integrada

Prueba de Johansen

Para iniciar creamos un Data Frame., luego crearemos un varselect para obtener un rezago óptimo para aplicar bien la prueba

```
> VARselect(DF,type =c("const")
+ )
$selection
AIC(n)  HQ(n)  SC(n)  FPE(n)
      6      2      2      6

$criteria
      1      2      3      4      5      6      7
AIC(n) -2.137138e+01 -2.160897e+01 -2.162354e+01 -2.162525e+01 -2.162725e+01 -2.165996e+01 -2.162671e+01
HQ(n)   -2.132856e+01 -2.153761e+01 -2.152363e+01 -2.149679e+01 -2.147025e+01 -2.147440e+01 -2.141261e+01
SC(n)   -2.126575e+01 -2.143293e+01 -2.137708e+01 -2.130837e+01 -2.123995e+01 -2.120224e+01 -2.109858e+01
FPE(n)  5.230366e-10  4.124338e-10  4.064888e-10  4.058307e-10  4.050724e-10  3.921143e-10  4.054754e-10
      8      9     10
AIC(n) -2.162452e+01 -2.162633e+01 -2.159497e+01
HQ(n)   -2.138187e+01 -2.135514e+01 -2.129524e+01
SC(n)   -2.102597e+01 -2.095736e+01 -2.085559e+01
FPE(n)  4.065047e-10  4.059439e-10  4.191006e-10
```

Y luego aplicamos la prueba de Johansen

```
> Prueba.johan<-ca.jo(DF,type = c("trace"),ecdet = c("const"), K= 2, spec = c("transitory"))
> summary(Prueba.johan)
```

```
#####
# Johansen-Procedure #
#####

Test type: trace statistic , without linear trend and constant in cointegration

Eigenvalues (lambda):
[1] 2.911082e-01 4.799018e-02 1.987961e-15

Values of teststatistic and critical values of test:


      test 10pct  5pct  1pct
r <= 1 |   9.34   7.52   9.24 12.97
r = 0  |  74.71 17.85 19.96 24.60

Eigenvectors, normalised to first column:
(These are the cointegration relations)


      LNPIBT.11  LNCPT.11  constant
LNPIBT.11  1.000000  1.000000  1.000000
LNCPT.11 -1.353264 -1.0577906 -0.9471609
constant  4.369717  0.1979894 -1.2797864

Weights W:
(This is the loading matrix)

      LNPIBT.11  LNCPT.11  constant
LNPIBT.d 0.01371691 -0.05751558 -9.13466e-13
LNCPT.d  0.02467108 -0.01349175  3.86842e-13
```



Se rechaza H_0 por tanto indica que no está co integrado



Se rechaza H_0 por tanto no está co integrado

VAR

Diferencio las series y hago un rezagó para el modelo el cual es optimo

```
> DTUNION<- diff(TUNION,1)
> VARselect(DTUNION,type =c("const"))
$selection
AIC(n)  HQ(n)  SC(n) FPE(n)
      5      5      1      5

$criteria
      1      2      3      4      5      6      7
AIC(n) -2.152814e+01 -2.157079e+01 -2.159289e+01 -2.161525e+01 -2.166238e+01 -2.162452e+01 -2.162948e+01
HQ(n)   -2.148516e+01 -2.149915e+01 -2.149259e+01 -2.148629e+01 -2.150477e+01 -2.143825e+01 -2.141455e+01
SC(n)   -2.142212e+01 -2.139408e+01 -2.134549e+01 -2.129717e+01 -2.127361e+01 -2.116507e+01 -2.109934e+01
FPE(n)  4.471452e-10 4.284845e-10 4.191429e-10 4.099088e-10 3.910911e-10 4.062618e-10 4.043598e-10
      8      9     10
AIC(n) -2.163059e+01 -2.159786e+01 -2.159631e+01
HQ(n)   -2.138701e+01 -2.132562e+01 -2.129541e+01
SC(n)   -2.102977e+01 -2.092635e+01 -2.085411e+01
FPE(n)  4.040505e-10 4.176791e-10 4.185575e-10
```

Para elegir una me basé en que son muy parecidas y elegí la primera fila.

```
VAR Estimation Results:
=====
Endogenous variables: LNPIBT, LNCPT
Deterministic variables: const
Sample size: 190
Log Likelihood: 1503.526
Roots of the characteristic polynomial:
0.4461 0.1131
Call:
VAR(y = DTUNION, p = 1, type = c("const"))

Estimation results for equation LNPIBT:
=====
LNPIBT = LNPIBT.l1 + LNCPT.l1 + const

              Estimate Std. Error t value Pr(>|t|)
LNPIBT.l1 0.3633686   0.0887511    4.094 6.30e-05 ***
LNCPT.l1  0.1733556   0.1007707    1.720  0.087 .
const      0.0023945   0.0005487    4.364 2.11e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.005492 on 187 degrees of freedom
Multiple R-Squared: 0.2395,    Adjusted R-squared: 0.2313
F-statistic: 29.44 on 2 and 187 DF,  p-value: 7.66e-12

Estimation results for equation LNCPT:
=====
LNCPT = LNPIBT.l1 + LNCPT.l1 + const
```

```

LNCPT = LNPIBT.11 + LNCPT.11 + const

              Estimate Std. Error t value Pr(>|t|)
LNPIBT.11  0.1195065   0.0860201   1.389   0.1664
LNCPT.11   0.1958606   0.0976699   2.005   0.0464 *
const      0.0033935   0.0005318   6.381 1.35e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.005323 on 187 degrees of freedom
Multiple R-Squared: 0.09494,    Adjusted R-squared: 0.08527
F-statistic: 9.809 on 2 and 187 DF,  p-value: 8.894e-05

Covariance matrix of residuals:
              LNPIBT      LNCPT
LNPIBT 3.016e-05 1.951e-05
LNCPT  1.951e-05 2.833e-05

Correlation matrix of residuals:
              LNPIBT      LNCPT
LNPIBT 1.0000 0.6675
LNCPT  0.6675 1.0000

```

Procedo a operar el modelo, con respecto a los resultados obtenidos anteriormente puedo concluir que en el modelo el PIB afecta casi directamente al Consumo del privado.

Ahora procedo a realizar la prueba de auto correlación

```

Portmanteau Test (asymptotic)

data: Residuals of VAR object VASH
Chi-squared = 101.63, df = 60, p-value = 0.0006363

```

```

ARCH (multivariate)

data: Residuals of VAR object VASH
Chi-squared = 62.185, df = 45, p-value = 0.04552

```

Comparándolos incluso sin hacer la prueba de la campana puedo indicar que el modelo tiene efecto arch y además tiene auto correlación

Ahora revisare que la normalidad del modelo

```

    JB-Test (multivariate)

data: Residuals of VAR object VASH
Chi-squared = 159.88, df = 4, p-value < 2.2e-16

$Skewness

    Skewness only (multivariate)

data: Residuals of VAR object VASH
Chi-squared = 27.18, df = 2, p-value = 1.253e-06

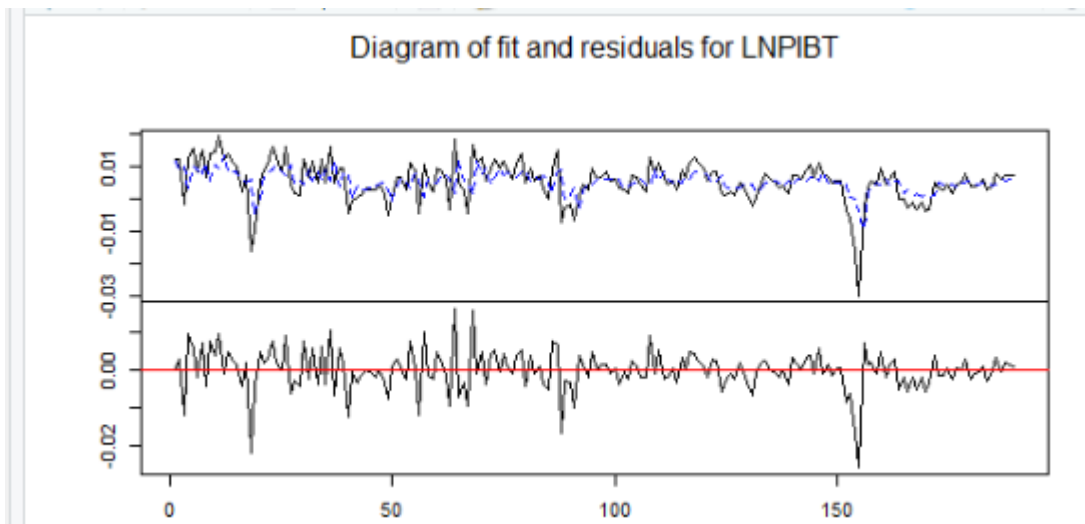
$Kurtosis

    Kurtosis only (multivariate)

data: Residuals of VAR object VASH
Chi-squared = 132.7, df = 2, p-value < 2.2e-16

```

Su P valor critico es casi cercano a cero + por tanto es menor que 0.05 lo que no es indica que cae en la zona de rechazo y no tiene una distribución normal.



Podríamos decir que el modelo no es muy bueno tiene altas y bajas volatilidades

```

> plot(stability(VASH,type = "Rec-CUSUM" ))
Error in plot.new() : figure margins too large

```

No puedo ver la gráfica, supongo que si marca este error es que las márgenes son demasiado amplias y por ende se salen de lo que es normal, por lo que sería un mal modelo

Causalidad de Granger

```

$Granger

      Granger causality H0: LNPIBT do not Granger-cause LNCPT

data:  VAR object VASH
F-Test = 1.9301, df1 = 1, df2 = 374, p-value = 0.1656

$Instant

      H0: No instantaneous causality between: LNPIBT and LNCPT

data:  VAR object VASH
Chi-squared = 58.563, df = 1, p-value = 1.965e-14

> causality(VASH, cause = LNCPT )
$Granger

      Granger causality H0: LNCPT do not Granger-cause LNPIBT

data:  VAR object VASH
F-Test = 2.9594, df1 = 1, df2 = 374, p-value = 0.08621

$Instant

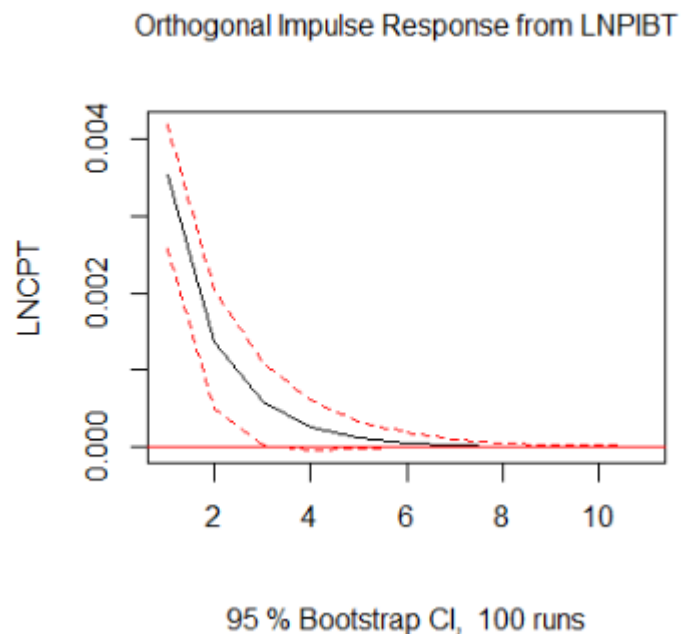
      H0: No instantaneous causality between: LNCPT and LNPIBT

data:  VAR object VASH
Chi-squared = 58.563, df = 1, p-value = 1.965e-14

```

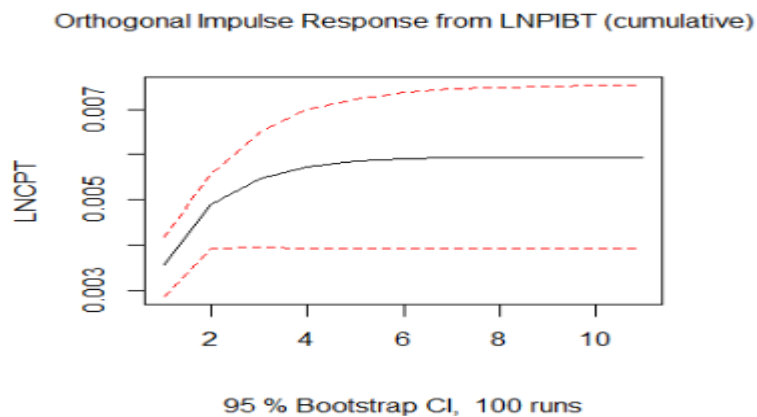
De estas pruebas se puede concluir que El PIB afecta a CP, o más bien los valores pasados o las innovaciones pasados afectan a la CP de la actualidad

Impulso Respuesta



En la gráfica podemos observar que la respuesta que hace el PIB con respecto al CP es cada vez menor, tal vez pueda deberse a que la tasa de participación del CP se vaya reduciendo con el tiempo, o que los impulsos de CP con respecto al PIB al inicio son demasiado altos pero que con el tiempo se normalizan.

Ahora procedo con los datos acumulados



Tal vez lo que mejor explique esta grafica seria que los datos acumulados cada van siendo más, y se deba aquí por el contrario una tasa de participación más activa del PC con respecto al PIB

Varianza de predicción del error.

```
> plot(VASH.TUNI, col = c("gray","yellow"))
Error in plot.new() : figure margins too large
```


Intente realizarlo, pero me marcaba error, intente solucionarlo, pero no sabía que pasaba.

VEC

Operación modelo VEC, BLOQUE 1

```
Call:
lm(formula = LNPIBT.d ~ ect1 + LNPIBT.dl1 + LNCPT.dl1 - 1, data = data.mat)

Residuals:
    Min       1Q   Median       3Q      Max
-0.0243873 -0.0021371  0.0005874  0.0036640  0.0161161

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
ect1          0.013717   0.003189   4.301 2.74e-05 ***
LNPIBT.dl1    0.376513   0.088369   4.261 3.23e-05 ***
LNCPT.dl1     0.125145   0.105362   1.188  0.236
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.005499 on 187 degrees of freedom
Multiple R-squared:  0.548,    Adjusted R-squared:  0.5407
F-statistic: 75.56 on 3 and 187 DF,  p-value: < 2.2e-16
```

ç

Observando el bloque 1 podría decir que el PIB no depende de CP pasados, es decir que el PIB no depende de meramente del consumo del privado pasados

Bloque 2

```
Response LNCPT.d :

Call:
lm(formula = LNCPT.d ~ ect1 + LNPIBT.dl1 + LNCPT.dl1 - 1, data = data.mat)

Residuals:
    Min       1Q   Median       3Q      Max
-0.0199386 -0.0023727  0.0003319  0.0030976  0.0130070

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
ect1          0.02467   0.00289   8.537 4.69e-15 ***
LNPIBT.dl1    0.11476   0.08007   1.433  0.153
LNCPT.dl1     0.05329   0.09546   0.558  0.577
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.004982 on 187 degrees of freedom
Multiple R-squared:  0.5632,    Adjusted R-squared:  0.5562
F-statistic: 80.37 on 3 and 187 DF,  p-value: < 2.2e-16
```

Para el bloque 2, podría decir que el PIB no está dependiendo del PC, pero el PC podría estar más dependiente del PIB

Ahora procederé hacer la bondad de ajuste del modelo convertimos a un modelo VAR


```
AUTO.VEC<- vec2var(Prueba.johan, r=1)
```

```
serial.test(AUTO.VEC)
```

```
Portmanteau Test (asymptotic)
data:  Residuals of VAR object AUTO.VEC
Chi-squared = 79.384, df = 58, p-value = 0.03262
```

> |


Cae en zona de rechazo se rechaza H0 por tanto tiene auto correlacion



```
arch.test(AUTO.VEC)
```


```
ARCH (multivariate)
data:  Residuals of VAR object AUTO.VEC
Chi-squared = 62.576, df = 45, p-value = 0.04243
```

Cae en la zona de rechazo por ende se rechaza H0 y por tanto tiene efecto arch



normality.test(AUTO.VEC)


```
$JB  
  
JB-Test (multivariate)  
  
data: Residuals of VAR object AUTO.VEC  
Chi-squared = 179.08, df = 4, p-value < 2.2e-16  
  
$Skewness  
  
Skewness only (multivariate)  
  
data: Residuals of VAR object AUTO.VEC  
Chi-squared = 42.267, df = 2, p-value = 6.634e-10  
  
$Kurtosis  
  
Kurtosis only (multivariate)  
  
data: Residuals of VAR object AUTO.VEC  
Chi-squared = 136.81, df = 2, p-value < 2.2e-16
```



Cae en la zona de rechazo por tanto no tiene una distribución normal.

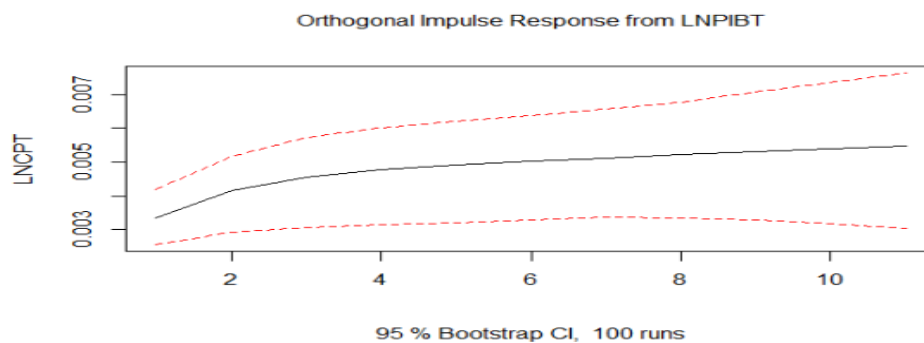
Análisis impulso respuesta

Ortogonal falsa:




En la gráfica podemos notar como el aumento en el PIB siempre es creciente, para el modelo los efectos que proporciona PC son graduales y cada vez mayores en el tiempo

Sin ortogonal




Con respecto a la podemos notar que los efectos que tiene PC en el PIB son graduales pero que se van “normalizando al pasar el tiempo

Ortogonal verdadera



Podemos notar en la gráfica que al inicio El PIB no se ve muy afectado por los cambios que se realizan en CP, pero con el tiempo estos cambios van afectando al PIB cada vez más en grandes medidas

Varianza de predicción del error.



viendo la varianza podría concluir que el CP es más afectado por el PIB que el PIB por el CP

Conclusiones.

Para concluir sobre cual modelo es mejor, pues podría decir que en primera instancia que sería el modelo VAR, debido a que desde un principio no es in modelo que este Co integrado y por tanto no necesitaría del modelo VEC, pero de igual manera, el modelo VEC es un modelo VAR, pero con otro nombre incluso para hacerle pruebas el modelo VEC hay que convertirlo A un modelo VAR.

Con respecto a las variables, podría decir que el PIB en algunas ocasiones se ve afectado por lo que pasa con el Consumo del privado, Esto tal vez se debe a que el consumo del privado sea más grande incluso que el consumo público y que sea más grande de lo que se piensa en Europa.